

背景介绍 整体设计和实现 数据质量

应用场景

#### 背景介绍

整体设计和实现

数据质量

应用场景

长链路且快速变化的业务

越来越多的实时数据需求

越来越高的数据质量要求



长链路且快速变化的业务

越来越多的实时数据需求

越来越高的数据质量要求

灵活可扩展



高效开发



高数据质量

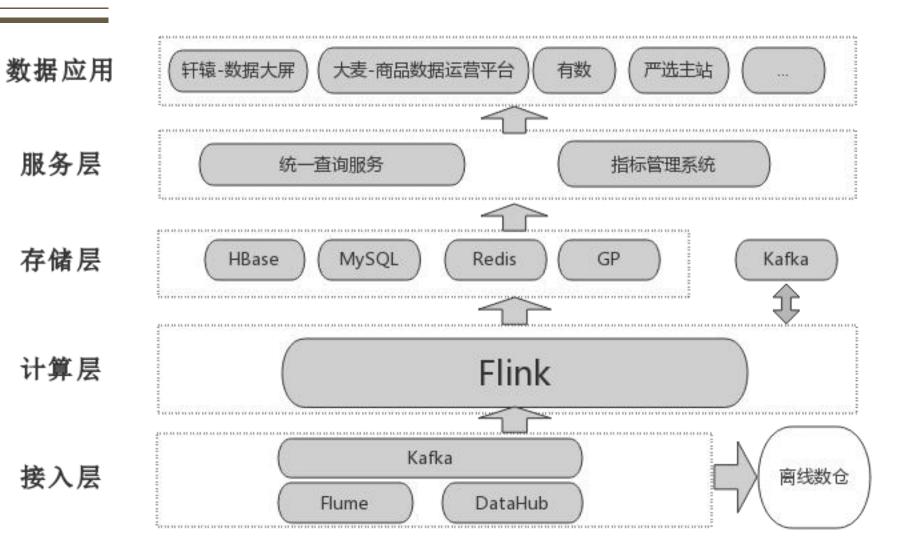
背景介绍

整体设计和实现

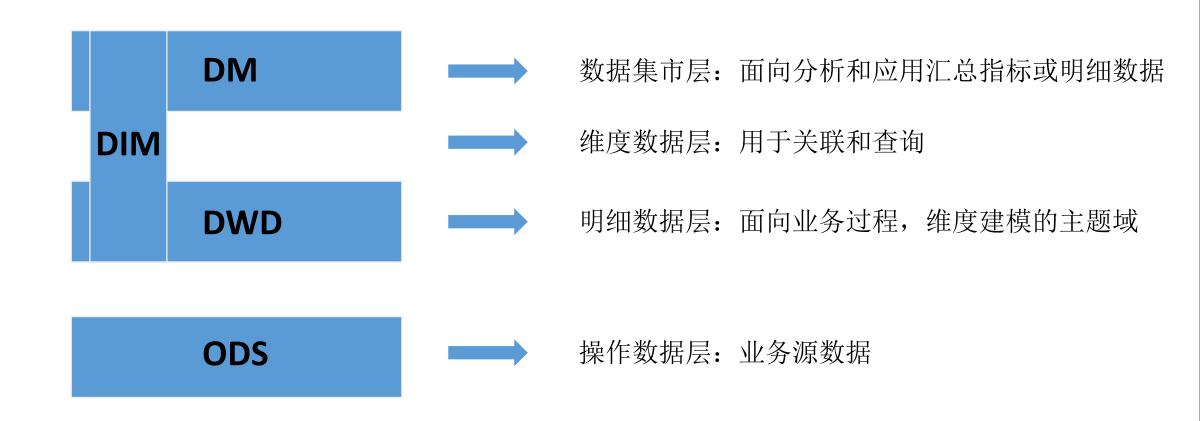
数据质量

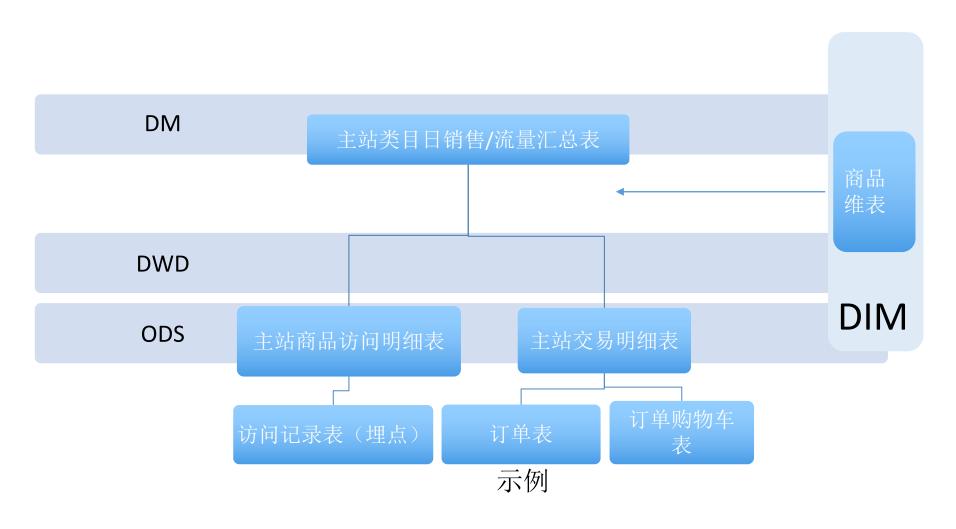
应用场景

## 整体架构

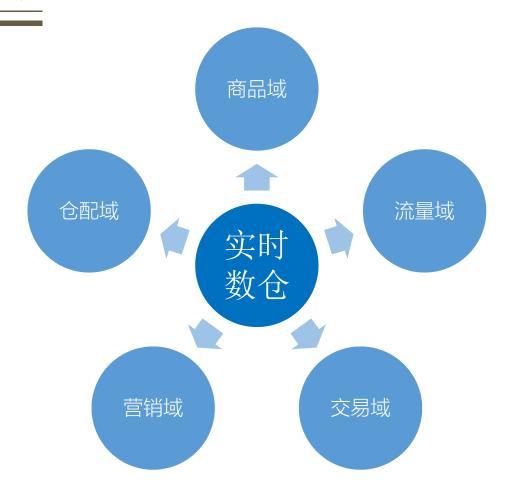


## 整体设计





## 设计-主题域



**5** 主题域

25 DWD模型数

135 数仓在线任务数

## 设计-主题域

效率: 主题域模型复用, 提高开发效率

交易明细模型(DWD):集市层模型(DM) = 1:10+,开发周期两人日/每模型

灵活: 封装业务逻辑, 快速应对变化



统一: 数据按业务域划分、方便维护

	Flink	Storm	Spark Streaming	
API(效率)	支持SQL、Table API、 Stream API	支持底层API、Trident API	支持SQL,流API	
延迟(性能)	毫秒级	毫秒级	秒级	
语义支持	At Least Once Exactly Once	At Least Once、Exactly Once	At Least Once	
容错机制	State和分布式快照持久 化	ACK	RDD	

Flink是适用于构建严选实时数仓的计算引擎

Greenplum:明细、多维分析关 MySQL: 汇总指标模型 DM HBase: 汇总指标指标(大量并发) Redis: 汇总、大列表TOPN DWD Kafka: 事实数据 Redis: 历史明细 ODS DIM Kafka: 事实数据 HBase: 维度数据

#### 计算

- 维度关联,Task本地缓存
- Hyperloglog聚合去重

数据量		HyperLoglog			Set		
总记录	去重	插入耗时	空间	误差	插入耗时	空间	误差
150w	41w	536755ms	12Kb	6‰	552153ms	14976Kb	0
$1\mathrm{w}$	5k	3663ms	6Kb	1‰	3700ms	180Kb	0

#### 存储

- MySQL: 窗口预聚合写入,延迟和负载平衡
- Greenplum 吞吐提高:
  - Sink端定位Segment, 直连Slave节点
  - 批量写入

背景介绍

整体设计和实现

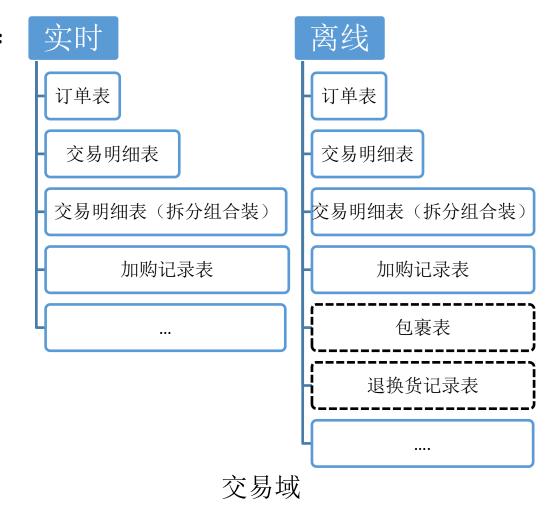
数据质量

应用场景

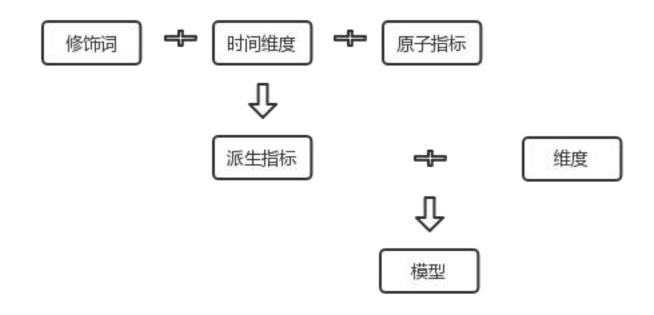
#### 实时&离线:

- 建模方法和分层基本统一
- 业务上主题域和模型设计同步
- 数据接入:源数据统一
- 数据产出:统一指标定义和接口

• DWD 主题域模型同步:



• DM层: 统一指标和应用模型定义



模型定义规范

## 数据一致性

仓颉 - 指标管理系统

指标定义



## 数据一致性

仓颉-指标管理系统

#### 模型定义



仓颉 - 指标管理系统

模型管理

+添加模型

模型名称	模型标识	模型描述	实时	位置
严选渠道商品实时销售数据	dm_goods_channel_item_sale		是	MySQL
严选渠道Group实时销售数据	dm_goods_channel_group_sale		是	MySQL
copy_严选仓库各类出库物流/小	copy_dm_outstore_type_expres		否	MySQL
严选仓库各类出库物流/小时分段	dm_outstore_type_express_cap		否	MySQL
copy_严选仓库各类入库小时分	copy_dm_intstore_type_capacit		否	MySQL
严选仓库各类入库小时分段产能	dm_intstore_type_capacity_hour		否	MySQL

## 质量监控

- 平台监控:
  - 任务失败监控
  - 异常日志监控
  - RPS异常监控
- 数据:
  - Kafka延迟监控



• 值班流程规范: 报警 ---> 恢复 ---> 通报 ---> 复盘

内容:

任务/数据表的上下游依赖关系



作用:

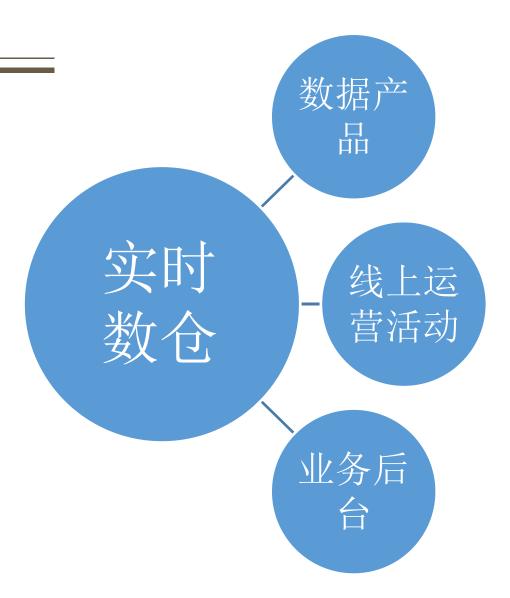
- 数据/任务主动调整可以周知关联的下游
- 任务异常及时判断影响范围,通知产品和业务方
- 指标异常时借助血缘定位问题

业务背景和问题

整体设计和实现

数据质量

应用场景



84 在线模型数

**110**+ 历史总模型数

<10s 延迟

#### 数据产品:

- 轩辕-数据大屏
- Vipapp-移动数据工作台
- 大麦-商品数据运营平台
- 神相-流量分析平台
- 刑天-推广渠道管理系统
- •



#### 数据应用

#### 线上运营活动:

- 热销商品榜单
- 活动用户消费排行
- 资源位转化率排序
- 用户二三单活动
- •



## 数据应用

#### 业务后台

- 仓配产能监控
- 物流时效监控
- 库存预警
- 商品变更通知
- •



# 性能优化

- MySQL迁移ES
- 维表落地Redis

## 开发效率

- SQL迁移
- UDF/UDAF扩展

# 数据质量

• 实时数据准确性校验

# 网严选

数据技术及产品部